

Sensado Remoto

Taller 3, Jorge Narváez Cavadía

1. Problema 1: Se aplicó el método de voto de la mayoría para varios tamaños de ventana, a los mapas de clasificación de Indian Pines y Pavia University obtenidos en el taller anterior. De los mapas resultantes se tomaron los valores del conjunto de prueba y se generaron matrices de confusión a partir de estas.

Para Indian Pines se muestra la comparación entre el mapa generado originalmente y los nuevos mapas de clasificación en la figura 1. Las correspondientes matrices de confusión se presentan en las tablas 1, 2, 3 y 4.

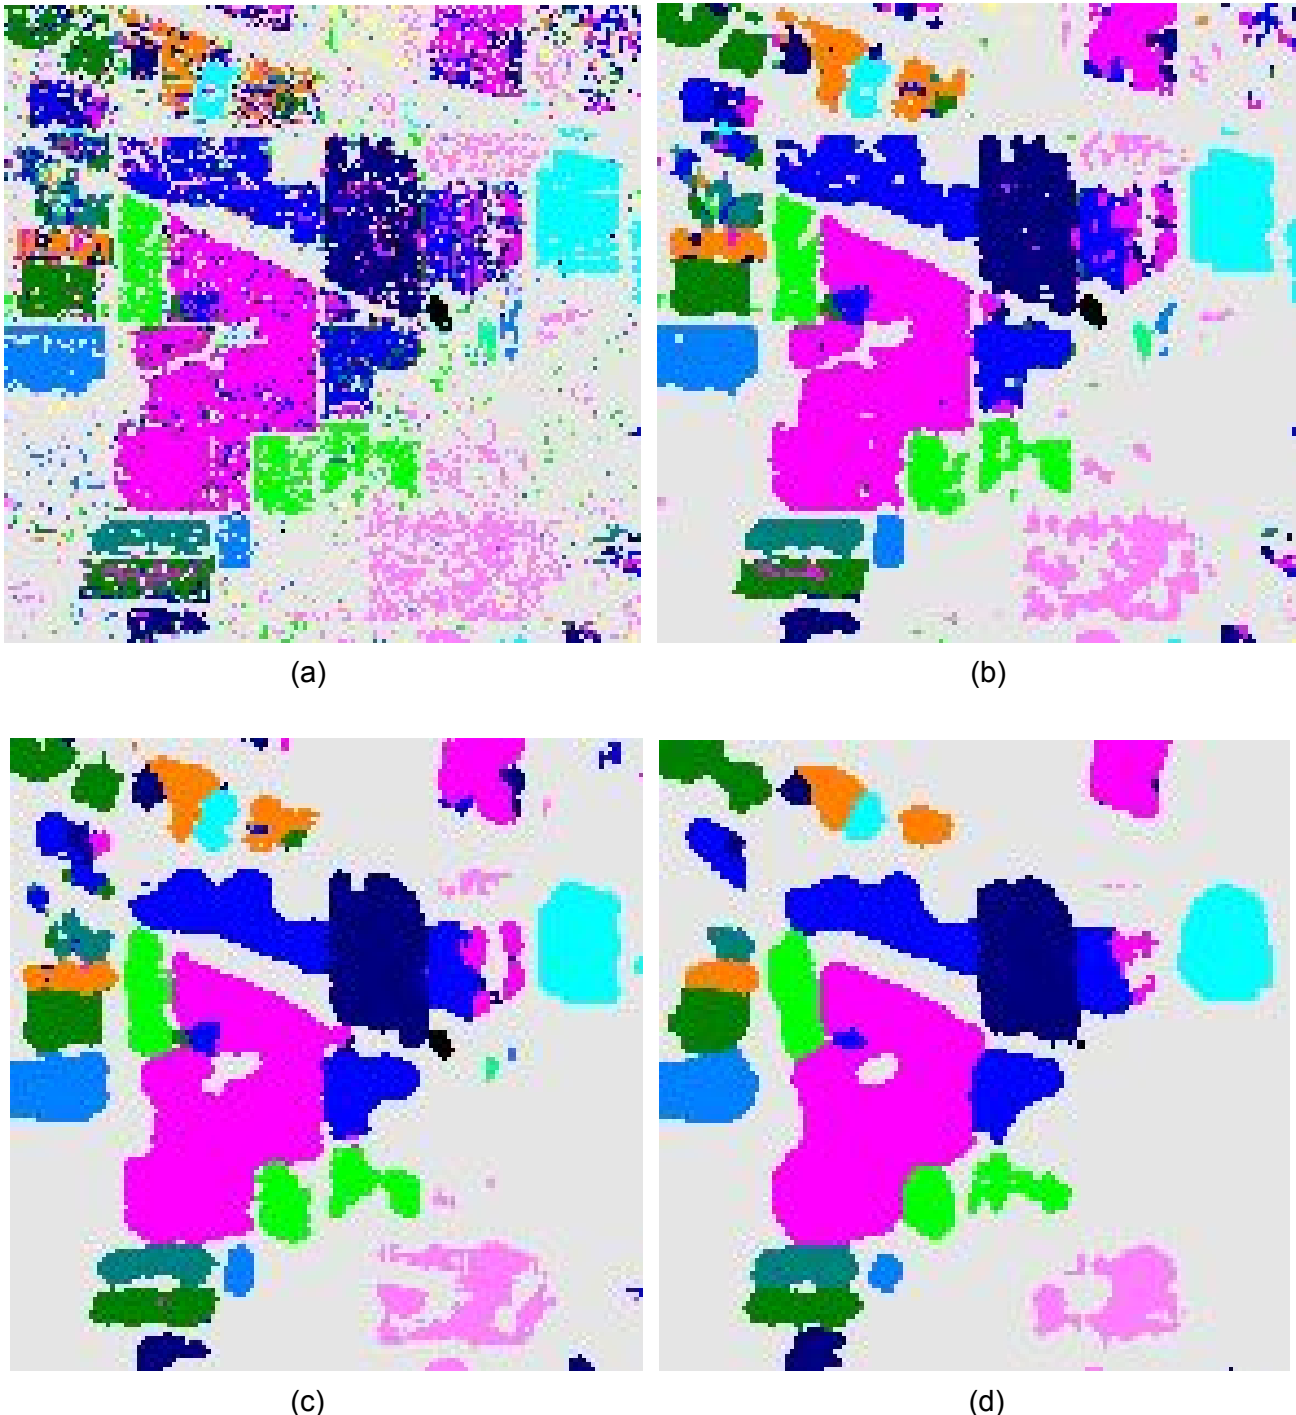


Figura 1: Mapas de clasificación de Indian Pines Aplicando el método del voto de la mayoría
(a) Original, (b) Ventana 3x3, (c) Ventana 5x5, (d) Ventana 9x9

Clase Real Predicción	No definido	Alfalfa	Corn notill	Corn mintill	Corn	Grass pasture	Grass trees	Grass PM	Hay windrowed	Oats	Soybean notill	Soybean mintill	Soybean clean	Wheat	Woods	Buildings GTD	Stone Steel Towers
No definido	0,8	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,1	0,0	0,0
Alfalfa	0,2	0,5	0,0	0,0	0,0	0,0	0,0	0,0	0,3	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Corn notill	0,2	0,0	0,6	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,1	0,1	0,0	0,0	0,0	0,0	0,0
Corn mintill	0,2	0,0	0,1	0,5	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,1	0,0	0,0	0,0	0,0	0,0
Corn	0,3	0,0	0,2	0,1	0,3	0,0	0,0	0,0	0,0	0,0	0,0	0,1	0,0	0,0	0,0	0,0	0,0
Grass pasture	0,3	0,0	0,0	0,0	0,0	0,7	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Grass trees	0,3	0,0	0,0	0,0	0,0	0,0	0,7	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Grass PM	0,2	0,0	0,0	0,0	0,0	0,0	0,0	0,8	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Hay windrowed	0,1	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,9	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Oats	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Soybean notill	0,1	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,7	0,1	0,0	0,0	0,0	0,0	0,0
Soybean mintill	0,1	0,0	0,1	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,1	0,7	0,0	0,0	0,0	0,0	0,0
Soybean clean	0,3	0,0	0,1	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,1	0,0	0,5	0,0	0,0	0,0	0,0
Wheat	0,1	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,9	0,0	0,0	0,0
Woods	0,5	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,5	0,0	0,0
Buildings GTD	0,7	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,1	0,1	0,0
Stone ST	0,4	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,1	0,0	0,0	0,0	0,0	0,6

Tabla 1: Matriz de confusión de la clasificación Original de Indian pines

Clase Real Predicción	No definido	Alfalfa	Corn notill	Corn mintill	Corn	Grass pasture	Grass trees	Grass PM	Hay windrowed	Oats	Soybean notill	Soybean mintill	Soybean clean	Wheat	Woods	Buildings GTD	Stone Steel Towers
No definido	0,9	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Alfalfa	0,3	0,7	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Corn notill	0,1	0,0	0,8	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,1	0,0	0,0	0,0	0,0	0,0
Corn mintill	0,1	0,0	0,1	0,8	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Corn	0,3	0,0	0,2	0,1	0,3	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Grass pasture	0,2	0,0	0,0	0,0	0,0	0,8	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Grass trees	0,2	0,0	0,0	0,0	0,0	0,0	0,8	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Grass PM	0,2	0,0	0,0	0,0	0,0	0,0	0,0	0,8	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Hay windrowed	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Oats	0,9	0,0	0,0	0,0	0,0	0,0	0,1	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Soybean notill	0,1	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,8	0,0	0,0	0,0	0,0	0,0	0,0
Soybean mintill	0,1	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,9	0,0	0,0	0,0	0,0	0,0
Soybean clean	0,2	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,6	0,0	0,0	0,0	0,0
Wheat	0,2	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,8	0,0	0,0	0,0
Woods	0,5	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,5	0,0	0,0
Buildings GTD	0,9	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Stone ST	0,3	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,7

Tabla 2: Matriz de confusión de la clasificación de Indian pines por voto de la mayoría con una ventana de 3x3

Clase Real Predicción	No definido	Alfalfa	Corn notill	Corn mintill	Corn	Grass pasture	Grass trees	Grass PM	Hay windrowed	Oats	Soybean notill	Soybean mintill	Soybean clean	Wheat	Woods	Buildings GTD	Stone Steel Towers
No definido	0,9	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Alfalfa	0,4	0,6	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Corn notill	0,1	0,0	0,8	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,1	0,0	0,0	0,0	0,0	0,0
Corn mintill	0,2	0,0	0,0	0,8	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Corn	0,4	0,0	0,1	0,0	0,4	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Grass pasture	0,2	0,0	0,0	0,0	0,0	0,8	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Grass trees	0,2	0,0	0,0	0,0	0,0	0,0	0,8	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Grass PM	0,5	0,0	0,0	0,0	0,0	0,0	0,0	0,5	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Hay windrowed	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Oats	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Soybean notill	0,1	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,8	0,0	0,0	0,0	0,0	0,0	0,0
Soybean mintill	0,1	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,9	0,0	0,0	0,0	0,0	0,0
Soybean clean	0,3	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,6	0,0	0,0	0,0	0,0
Wheat	0,2	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,8	0,0	0,0	0,0
Woods	0,6	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,4	0,0	0,0
Buildings GTD	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Stone ST	0,2	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,8

Tabla 3: Matriz de confusión de la clasificación de Indian pines por voto de la mayoría con una ventana de 5x5

Clase Real Predicción	No definido	Alfalfa	Corn notill	Corn mintill	Corn	Grass pasture	Grass trees	Grass PM	Hay windrowed	Oats	Soybean notill	Soybean mintill	Soybean clean	Wheat	Woods	Buildings GTD	Stone Steel Towers
No definido	0,9	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Alfalfa	0,9	0,1	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Corn notill	0,2	0,0	0,7	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Corn mintill	0,3	0,0	0,0	0,7	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Corn	0,7	0,0	0,0	0,0	0,3	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Grass pasture	0,3	0,0	0,0	0,0	0,0	0,7	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Grass trees	0,3	0,0	0,0	0,0	0,0	0,0	0,7	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Grass PM	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Hay windrowed	0,1	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,9	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Oats	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Soybean notill	0,2	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,8	0,0	0,0	0,0	0,0	0,0	0,0
Soybean mintill	0,2	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,8	0,0	0,0	0,0	0,0	0,0
Soybean clean	0,4	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,5	0,0	0,0	0,0	0,0
Wheat	0,1	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,9	0,0	0,0	0,0
Woods	0,7	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,3	0,0	0,0
Buildings GTD	0,9	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Stone ST	0,3	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,7

Tabla 4: Matriz de confusión de la clasificación de Indian pines por voto de la mayoría con una ventana de 9x9

Para Pavia University se muestra la comparación entre el mapa generado originalmente y los nuevos mapas de clasificación en la figura 2. Las matrices de confusión se presentan en las tablas 5, 6, 7 y 8.

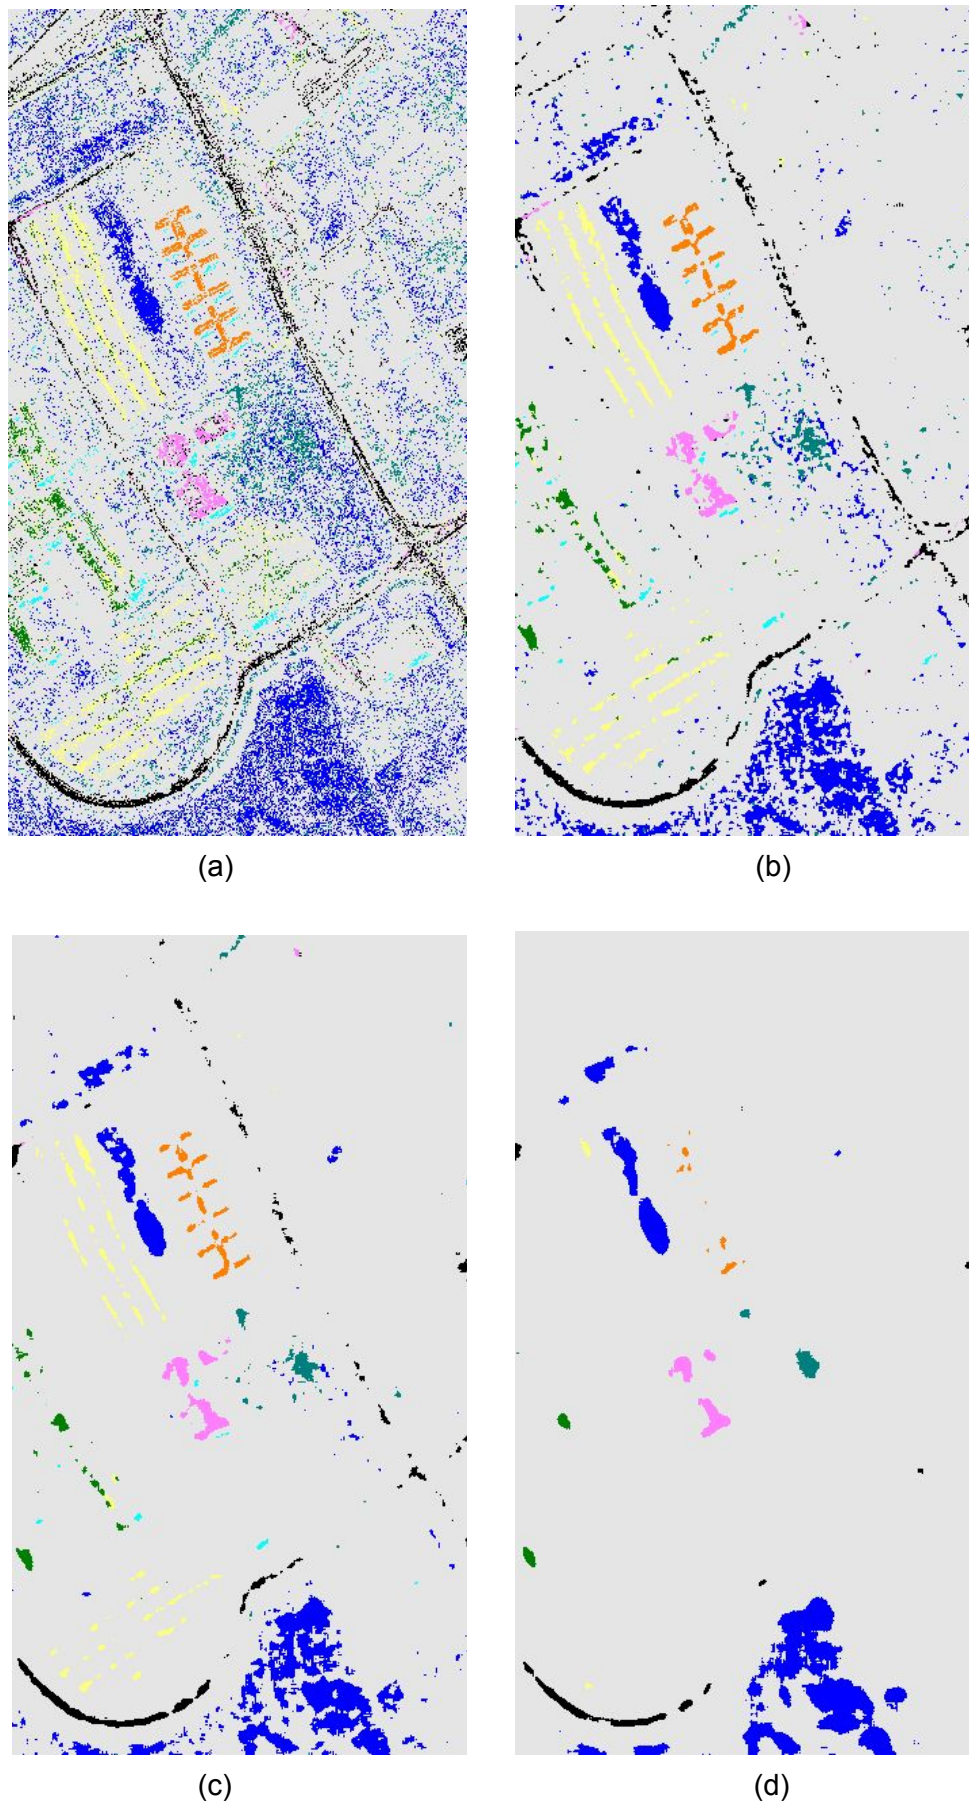


Figura 2: Mapas de clasificación de Pavia University aplicando el método del voto de la mayoría
(a) Original, (b) Ventana 3x3, (c) Ventana 5x5, (d) Ventana 9x9

Clase Real Predicción	No definido	Asphalt	Meadows	Gravel	Trees	P Metal sheets	Bare Soil	Bitumen	SB Bricks	Shadows
No definido	0,9	0,0	0,1	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Asphalt	0,6	0,4	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Meadows	0,6	0,0	0,4	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Gravel	0,6	0,0	0,0	0,3	0,0	0,0	0,0	0,0	0,1	0,0
Trees	0,7	0,0	0,0	0,0	0,2	0,0	0,0	0,0	0,0	0,0
P Metal sheets	0,4	0,0	0,0	0,0	0,0	0,6	0,0	0,0	0,0	0,0
Bare Soil	0,7	0,0	0,1	0,0	0,0	0,0	0,2	0,0	0,0	0,0
Bitumen	0,3	0,1	0,0	0,0	0,0	0,0	0,0	0,5	0,0	0,0
SB Bricks	0,6	0,0	0,0	0,1	0,0	0,0	0,0	0,0	0,3	0,0
Shadows	0,6	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,4

Tabla 5: Matriz de confusión de la clasificación Original de Pavia University

Clase Real Predicción	No definido	Asphalt	Meadows	Gravel	Trees	P Metal sheets	Bare Soil	Bitumen	SB Bricks	Shadows
No definido	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Asphalt	0,7	0,3	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Meadows	0,6	0,0	0,4	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Gravel	0,7	0,0	0,0	0,3	0,0	0,0	0,0	0,0	0,1	0,0
Trees	0,9	0,0	0,0	0,0	0,1	0,0	0,0	0,0	0,0	0,0
P Metal sheets	0,3	0,0	0,0	0,0	0,0	0,7	0,0	0,0	0,0	0,0
Bare Soil	0,8	0,0	0,0	0,0	0,0	0,0	0,1	0,0	0,0	0,0
Bitumen	0,4	0,0	0,0	0,0	0,0	0,0	0,0	0,6	0,0	0,0
SB Bricks	0,6	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,4	0,0
Shadows	0,8	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,2

Tabla 6: Matriz de confusión de la clasificación de Pavia University por voto de la mayoría con una ventana de 3x3

Clase Real Predicción	No definido	Asphalt	Meadows	Gravel	Trees	P Metal sheets	Bare Soil	Bitumen	SB Bricks	Shadows
No definido	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Asphalt	0,8	0,2	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Meadows	0,6	0,0	0,4	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Gravel	0,8	0,0	0,0	0,2	0,0	0,0	0,0	0,0	0,0	0,0
Trees	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
P Metal sheets	0,5	0,0	0,0	0,0	0,0	0,5	0,0	0,0	0,0	0,0
Bare Soil	0,9	0,0	0,0	0,0	0,0	0,0	0,1	0,0	0,0	0,0
Bitumen	0,5	0,0	0,0	0,0	0,0	0,0	0,0	0,5	0,0	0,0
SB Bricks	0,7	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,3	0,0
Shadows	0,9	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,1

Tabla 7: Matriz de confusión de la clasificación de Pavia University por voto de la mayoría con una ventana de 5x5

Clase Real Predicción	No definido	Asphalt	Meadows	Gravel	Trees	P Metal sheets	Bare Soil	Bitumen	SB Bricks	Shadows
No definido	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Asphalt	0,9	0,1	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Meadows	0,7	0,0	0,3	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Gravel	0,9	0,0	0,0	0,1	0,0	0,0	0,0	0,0	0,0	0,0
Trees	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
P Metal sheets	0,9	0,0	0,0	0,0	0,0	0,1	0,0	0,0	0,0	0,0
Bare Soil	0,9	0,0	0,0	0,0	0,0	0,0	0,1	0,0	0,0	0,0
Bitumen	0,6	0,0	0,0	0,0	0,0	0,0	0,0	0,4	0,0	0,0
SB Bricks	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Shadows	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0

Tabla 8: Matriz de confusión de la clasificación de Pavia University por voto de la mayoría con una ventana de 9x9

Como se observa en las matrices de confusión y en los mapas de clasificación, hay una mejoría en la clasificación de Indian Pines utilizando el método de voto de la mayoría con un tamaño de ventana de 3x3. Para el resto de casos, la clasificación empeora con este método. Lo cual se da ya sea por un tamaño de ventana muy grande, que distorsiona la distribución de los datos. O en el caso de Pavia University porque en la clasificación original se tenía un rendimiento menor al 50% en la mayoría de clases. Entonces al escoger por mayoría se tenderá a escoger clases equivocadas.

2. Problema 2: Se implementó una función de segmentación para imágenes espectrales a partir del algoritmo de soft-clustering conocido como “fuzzy-c means”. El proceso consiste en la siguiente serie de pasos:

1. Se aplica fuzzy-c means a los datos espectrales de las imágenes, obteniendo mapas de pertenencia difusa para cada clase.
2. Se aplica un filtro gaussiano a cada mapa de pertenencia difusa.
3. Se utiliza el “Método Otsu” para definir un umbral para cada matriz de pertenencia que permita decidir si una muestra pertenece o no a dicha clase.
4. A partir de los umbrales se obtienen mapas binarios de pertenencia para cada clase. Dado el método utilizado habrán muestras que pertenecen a más de una clase.
5. Las muestras que pertenecen a más de una clase se etiquetan como fondo de la imagen, interpretando que al no haber certeza de que pertenecen a una clase en particular, no conviene que pertenezcan a un segmento particular.
6. A cada mapa binario se aplica un filtro morfológico “Opening” para diferenciar secciones débilmente unidas.
7. Se etiquetan todos los segmentos de cada mapa y se unen en un solo mapa de segmentos.

El algoritmo fuzzy-c means posee problemas conocidos para separar datos con muchas características. Por lo que no se aplicó directamente sobre los datos de las imágenes hiperespectrales como las de Indian Pines, Pavia University, Cupride y Hyperion. Para estas se aplicó en primera instancia PCA para reducir la dimensionalidad.

A continuación se muestran los mapas de segmentación obtenidos para las imágenes de Sentinel-2 (Figura 3), Hyperion (Figura 4-a), Landsat-8 (Figura 4-b), Pavia university (Figura 5-a), Cupride (Figura 5-b) e Indian Pines (Figura 6).






Figura 3: Mapa de segmentación de la imagen de Sentinel-2 Barrancabermeja




(a)




(b)

Figura 4: Mapas de segmentación de las imágenes de (a) Hyperion Barrancabermeja y (b) Landsat-8 Río Guaviare



(a)



(b)

Figura 5: Mapas de segmentación de las imágenes de (a) Pavia University y (b) Cupride




Figura 6: Mapa de segmentación de la imagen de Indian Pines

3. Problema 3: Usando los mapas de segmentación de Indian Pines y Pavia university y sus mapas de clasificación, se procede a clasificar cada uno de los segmentos de acuerdo a la clase que más se encuentra dentro de cada segmento. Mientras que para las secciones etiquetadas como fondo, se copian los valores de la clasificación original.

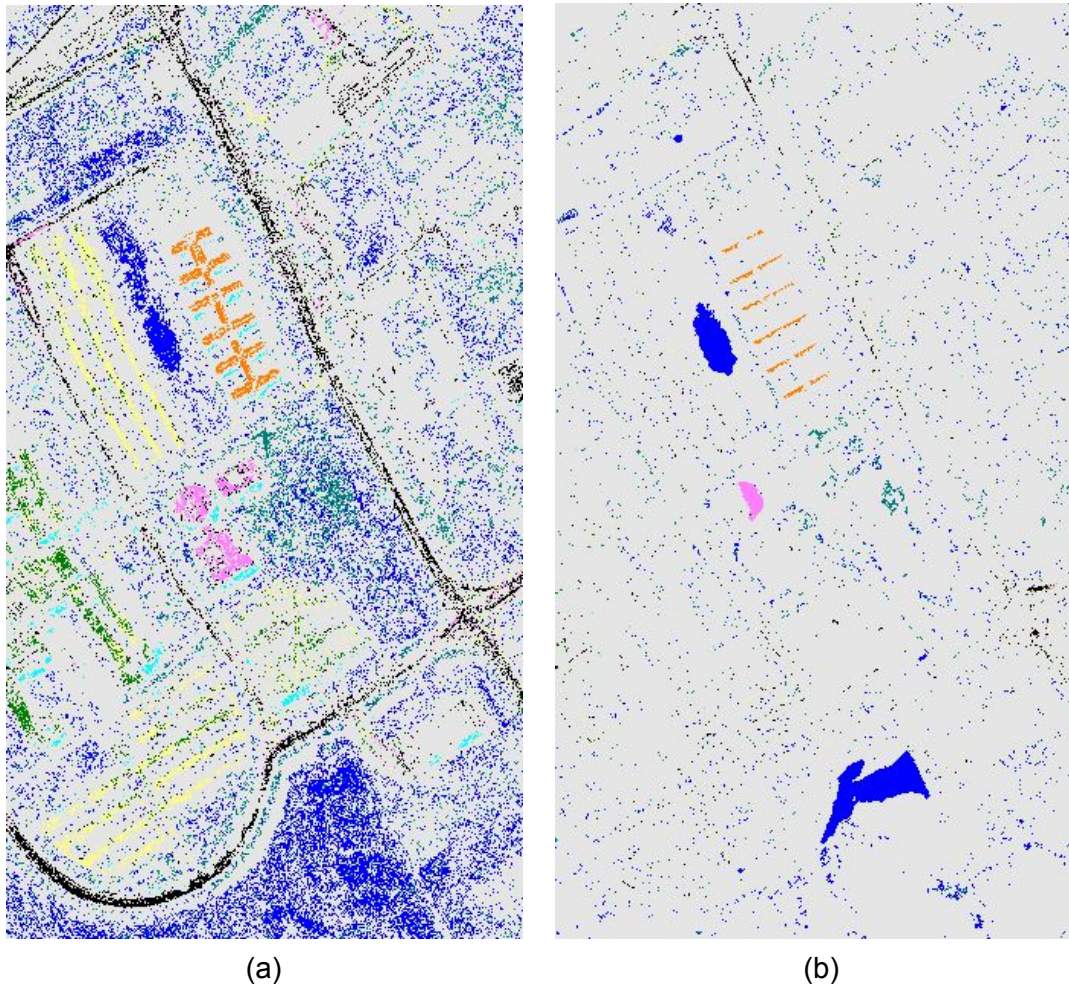


Figura 7: Mapas de clasificación de Pavia University (a) Original, (b) aplicando el método de clasificación de segmentos

Clase Real Predicción	No definido	Asphalt	Meadows	Gravel	Trees	P Metal sheets	Bare Soil	Bitumen	SB Bricks	Shadows
No definido	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Asphalt	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Meadows	0,9	0,0	0,1	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Gravel	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Trees	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
P Metal sheets	0,9	0,0	0,0	0,0	0,0	0,1	0,0	0,0	0,0	0,0
Bare Soil	0,9	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Bitumen	0,9	0,0	0,0	0,0	0,0	0,0	0,0	0,1	0,0	0,0
SB Bricks	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Shadows	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0

Tabla 9: Matriz de confusión de la clasificación de segmentos de Pavia University

Se compara el nuevo mapa de clasificación de Pavia University con el original en la figura 7 y se presenta la matriz de confusión del nuevo mapa de clasificación generada a partir del conjunto de prueba en la tabla 9. Para Indian Pines se presenta la comparación entre la nueva clasificación y la original en la figura 8 y la respectiva matriz de confusión en la tabla 10.

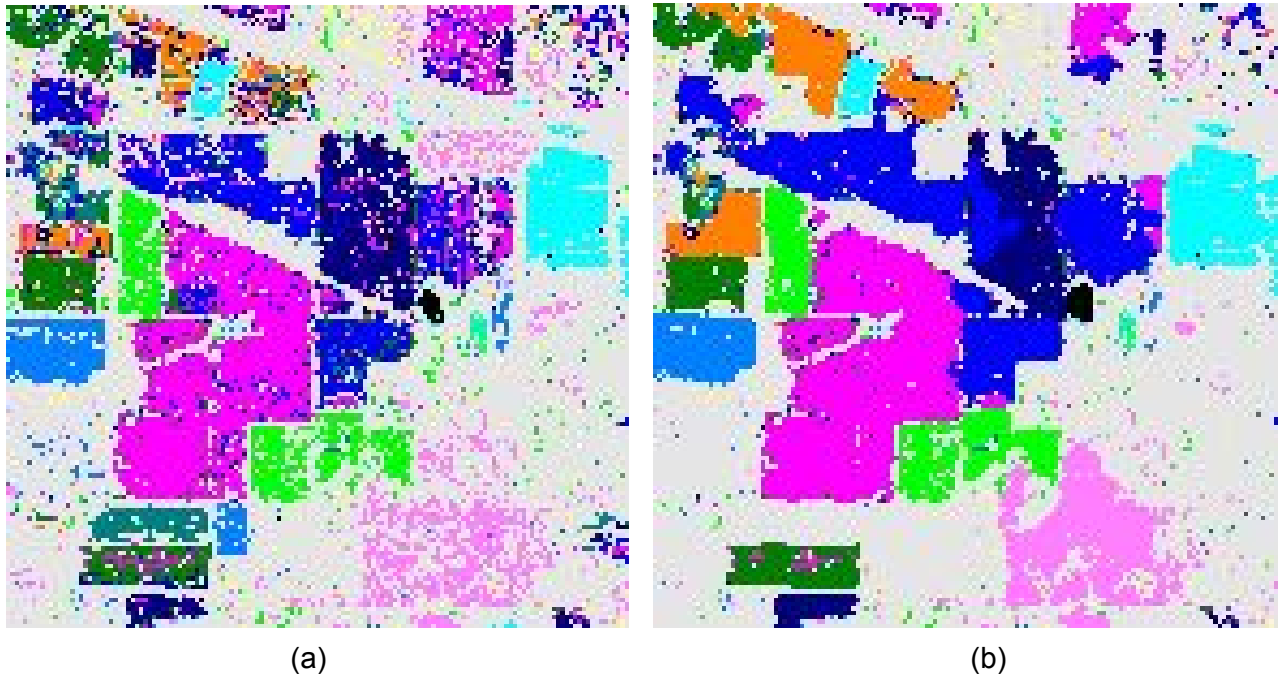


Figura 8: Mapas de clasificación de Indian Pines (a) Original, (b) aplicando el método de clasificación de segmentos

Clase Real Predicción	No definido	Alfalfa	Corn notill	Corn mintill	Corn	Grass pasture	Grass trees	Grass PM	Hay windrowed	Oats	Soybean notill	Soybean mintill	Soybean clean	Wheat	Woods	Buildings GTD	Stone Steel Towers
No definido	0,8	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Alfalfa	0,1	0,8	0,0	0,0	0,0	0,0	0,0	0,0	0,1	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Corn notill	0,1	0,0	0,8	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,1	0,0	0,0	0,0	0,0	0,0
Corn mintill	0,1	0,0	0,1	0,7	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,1	0,0	0,0	0,0	0,0
Corn	0,2	0,0	0,2	0,1	0,1	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,3	0,0	0,0	0,0	0,0
Grass pasture	0,3	0,0	0,0	0,0	0,0	0,6	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Grass trees	0,2	0,0	0,0	0,0	0,0	0,0	0,8	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Grass PM	0,3	0,0	0,0	0,0	0,0	0,0	0,0	0,5	0,1	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Hay windrowed	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Oats	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Soybean notill	0,1	0,0	0,2	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,6	0,0	0,1	0,0	0,0	0,0	0,0
Soybean mintill	0,1	0,0	0,1	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,8	0,0	0,0	0,0	0,0	0,0
Soybean clean	0,2	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,7	0,0	0,0	0,0	0,0
Wheat	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Woods	0,5	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,5	0,0	0,0
Buildings GTD	0,9	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Stone ST	0,2	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,8

Tabla 10: Matriz de confusión de la clasificación de segmentos de Indian Pines

Al comparar la matriz de confusión en la tabla 10 y la matriz de confusión de la clasificación original de Indian Pines en la tabla 1. Se observa que se mejora la clasificación de 7 clases, se empeora en 8 y se obtiene igual rendimiento en 2. Por lo que en general se obtienen rendimientos muy parecidos. Para Pavia University en cambio, hay una drástica reducción en el rendimiento, ya que al tener en la clasificación original un número de muestras mayor al 50% que se confunden con la clase “No definido”, la gran mayoría de los segmentos terminan clasificados como dicha clase.

4. Problema 4: Usando los mapas de segmentación de las imágenes de Sentinel-2, Hyperion y Landsat-8, y sus mapas de clasificación, se procede a clasificar cada uno de los segmentos de acuerdo a la clase que más se encuentra dentro de cada segmento. Mientras que para las secciones etiquetadas como fondo, se copian los valores de la clasificación original.

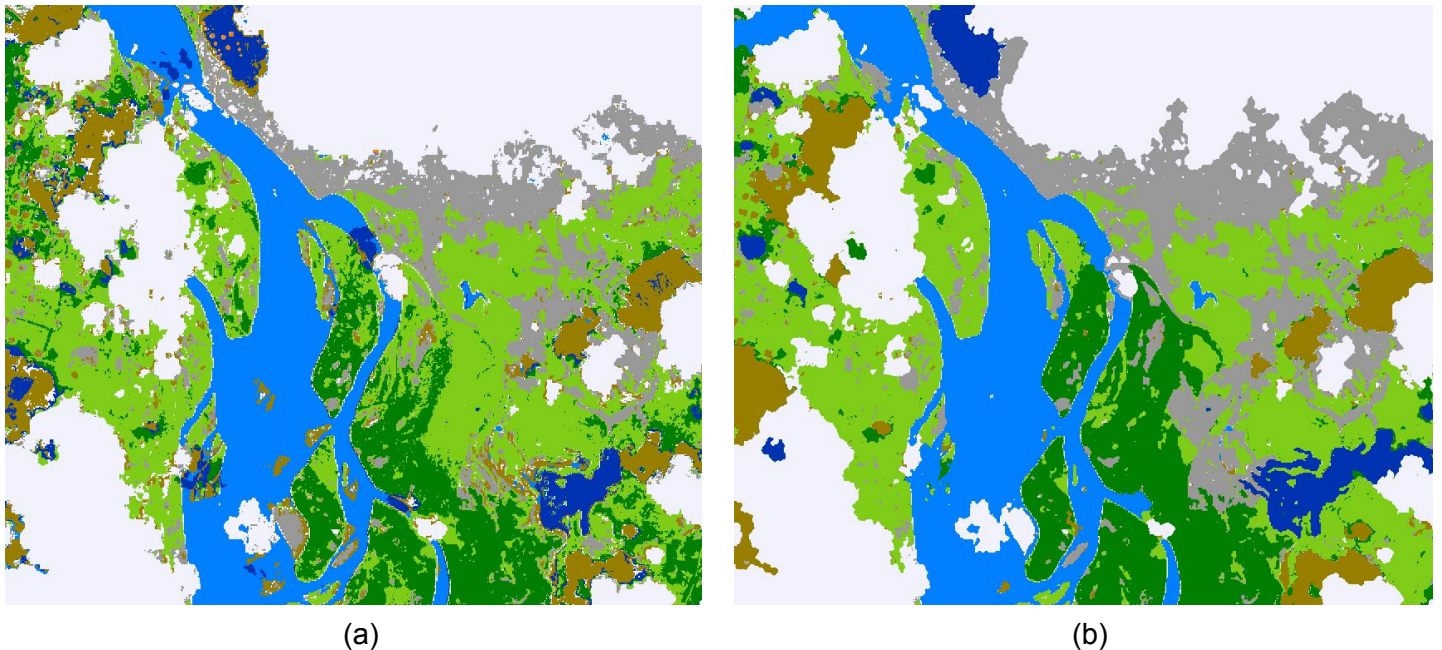


Figura 9: Mapas de clasificación de la imagen de Sentinel-2 (a) Original, (b) aplicando el método de clasificación de segmentos

Clase Real Predicción	Ciudad	Nubes	Bosque	Rio	Tanques	Suelo	Vegetación	Agua Estancada
Ciudad	1,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Nubes	0,0	1,0	0,0	0,0	0,0	0,0	0,0	0,0
Bosque	0,0	0,0	0,9	0,0	0,0	0,0	0,1	0,0
Rio	0,0	0,0	0,0	1,0	0,0	0,0	0,0	0,0
Tanques	0,0	0,2	0,0	0,0	0,0	0,0	0,0	0,8
Suelo	0,1	0,0	0,1	0,0	0,0	0,8	0,0	0,0
Vegetación	0,2	0,0	0,1	0,0	0,0	0,0	0,8	0,0
Agua Estancada	0,0	0,0	0,0	0,0	0,0	0,0	0,0	1,0

Tabla 11: Matriz de confusión de la clasificación de segmentos de Sentinel-2

Los resultados para la imagen de sentinel-2 se encuentran en la figura 9 y la tabla 11. Para la imagen de Hyperion en la figura 10 y la tabla 12. Y para la imagen de Landsat-8 en la figura 11 y la tabla 13.

El rendimiento para el método de clasificación de segmentos para la imagen de Sentinel-2 es muy parecido al original con excepción de la clase “Tanques” que es confundida con la clase “Agua Estancada”, mientras que en la clasificación original se tenía un rendimiento del 80% para esta clase. Para la imagen de Hyperion, el rendimiento es casi idéntico al original, disminuyendo tan solo una décima en la clase “Suelo” con respecto a los resultados originales.

En la imagen de Landsat-8, el rendimiento disminuyó considerablemente en las clases “Río” y “Bosque”. Se observa en el mapa de segmentación (Figura 4-b) que no hay diferenciación entre el Río Guaviare y otras secciones, y al ser menor el área que cubre el río, el espacio que este ocupa en la imagen termina siendo clasificado según sus alrededores.

El acierto en la clasificación utilizando este método depende mucho de que la segmentación diferencie correctamente las zonas de diferente clasificación.




Figura 10: Mapas de clasificación de la imagen de Sentinel-2 (a) Original, (b) aplicando el método de clasificación de segmentos

Clase Real Predicción	Ciudad	Bosque	Río	Suelo	Ciénaga	Vegetación	Agua Estancada
Ciudad	1,0	0,0	0,0	0,0	0,0	0,0	0,0
Bosque	0,0	0,8	0,0	0,0	0,0	0,2	0,0
Río	0,0	0,0	1,0	0,0	0,0	0,0	0,0
Suelo	0,3	0,0	0,0	0,7	0,0	0,0	0,0
Ciénaga	0,0	0,1	0,0	0,0	0,9	0,0	0,0
Vegetación	0,0	0,0	0,0	0,0	0,0	1,0	0,0
Agua Estancada	0,0	0,0	0,0	0,0	0,0	0,0	1,0

Tabla 12: Matriz de confusión de la clasificación de segmentos de Hyperion

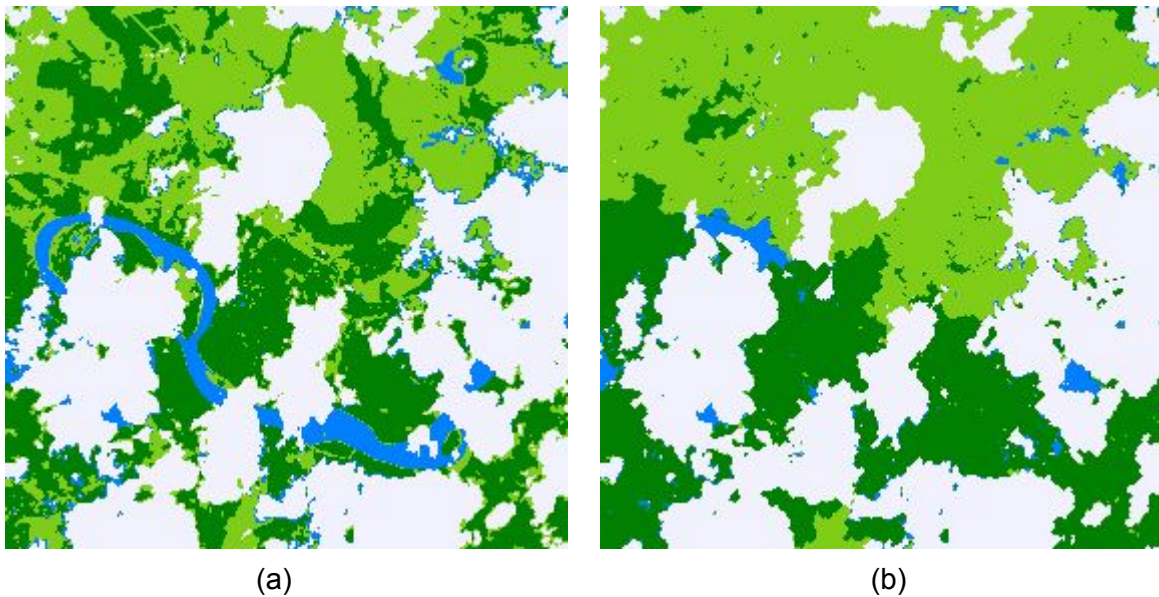


Figura 11: Mapas de clasificación de la imagen de Landsat-8 (a) Original, (b) aplicando el método de clasificación de segmentos

Clase Real Predicción				
	Nubes	Bosque	Rio	Vegetación
Nubes	1,00	0,00	0,00	0,00
Bosque	0,00	0,60	0,00	0,40
Rio	0,06	0,80	0,14	0,00
Vegetación	0,00	0,00	0,00	1,00

Tabla 13: Matriz de confusión de la clasificación de segmentos de Landsat-8

5. Problema 5: Usando el mapa de segmentación de la imagen de Cupride, se calculó la media de las reflectancias de cada segmento y se aplica sobre estos datos el algoritmo VCA para seleccionar los endmembers. Se realizó esta selección y el posterior proceso de desmezclado para varios números de endmembers. Se calculó el error entre los datos de reflectancia y la multiplicación de los endmember y abundancias calculadas para generar una gráfica del error en relación al número de endmembers seleccionados. Esta gráfica se utiliza para seleccionar un número de endmember adecuado. Se presenta en la figura 12.

Se seleccionaron 6 endmembers, mostrados en la figura 13. Los mapas de abundancia para cada uno de los endmembers se muestran en la figura 14.




Figura 12: Error de Unmixing vs Numero de Endmembers, Cupride

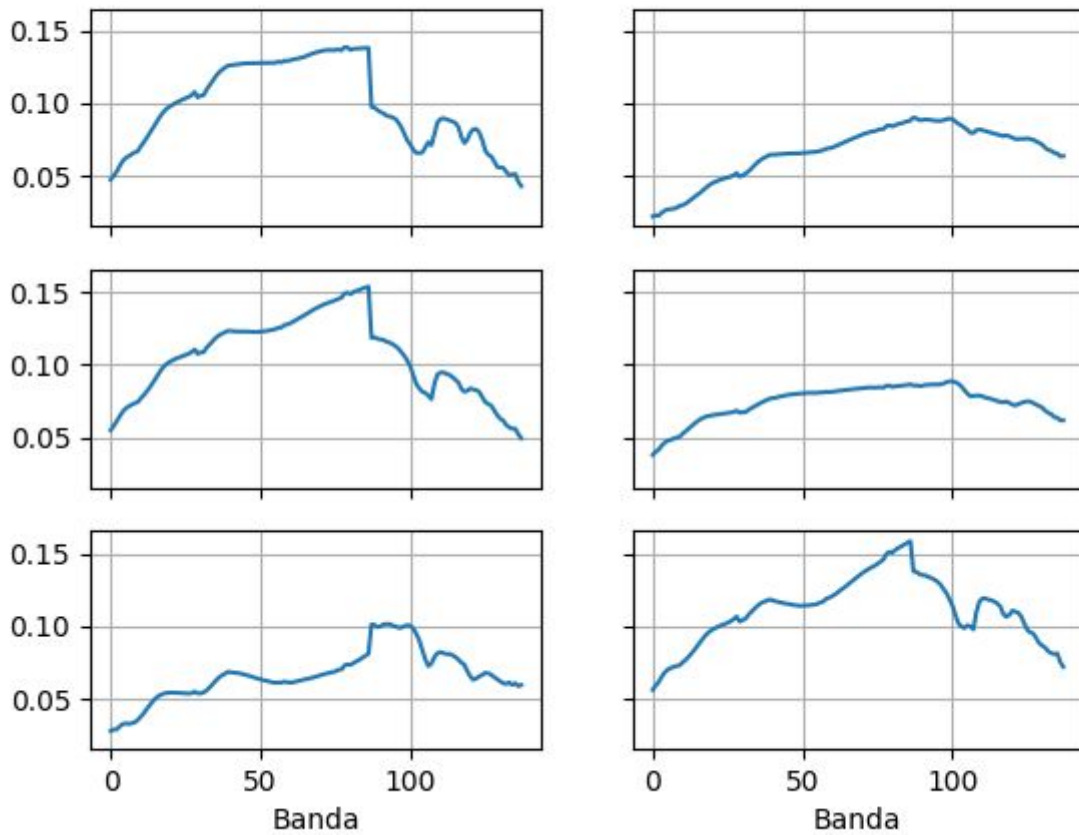





Figura 13: 6 Endmembers seleccionados por VCA, Cupride




(1)




(2)




(3)



(4)



(5)



(6)

Figura 14: Mapas de abundancias, Cupride.

6. Problema 6: Usando el mapa de segmentación de la imagen de Hyperion, se calculó la media de las reflectancias de cada segmento y se aplica sobre estos datos el algoritmo VCA para seleccionar los endmembers. Se realizó esta selección y el posterior proceso de desmezclado para varios números de endmembers. Se calculó el error entre los datos de reflectancia y la multiplicación de los endmember y abundancias calculadas para generar una gráfica del error en relación al número de endmembers seleccionados. Esta gráfica se utiliza para seleccionar un número de endmember adecuado. Se presenta en la figura 15. Se seleccionaron 5 endmembers, mostrados en la figura 16. Los mapas de abundancia para cada uno de los endmembers se muestran en la figura 17




Figura 15: Error de Unmixing vs Número de Endmembers, Hyperion






Figura 16: 5 Endmembers seleccionados por VCA, Hyperion




(1)




(2)



(3)



(4)



(5)

Figura 17: Mapas de abundancias, Hyperion.